


Introdução:

O projeto tem como objetivo desenvolver uma solução digital com base em dados reais que seja capaz de prever, monitorar ou mitigar os impactos de eventos naturais extremos, aplicando de forma integrada os conhecimentos em lógica, programação e estruturação de dados.

O evento extremo escolhido para esse projeto foi o de incêndios florestais escolhido do site: <https://disasterscharter.org/>.

Desenvolvimento:

Esp32



A proposta deste sistema é desenvolver um dispositivo para ser instalado em áreas florestais com o objetivo de monitorar as condições ambientais e prevenir incêndios. O dispositivo realiza a medição de temperatura e umidade utilizando o sensor DHT22. Como a plataforma WOKWI não possui um sensor específico para medir a velocidade do vento, foi utilizado um potenciômetro para simular essa variável.

O sistema conta com quatro LEDs que indicam o nível de alerta para risco de incêndio na área monitorada:

- **Verde:** risco baixo
- **Amarelo:** risco moderado
- **Laranja:** risco alto
- **Vermelho:** incêndio iminente ou em andamento

Para o nível vermelho ser acionado a temperatura tem que estar acima dos 40 °C

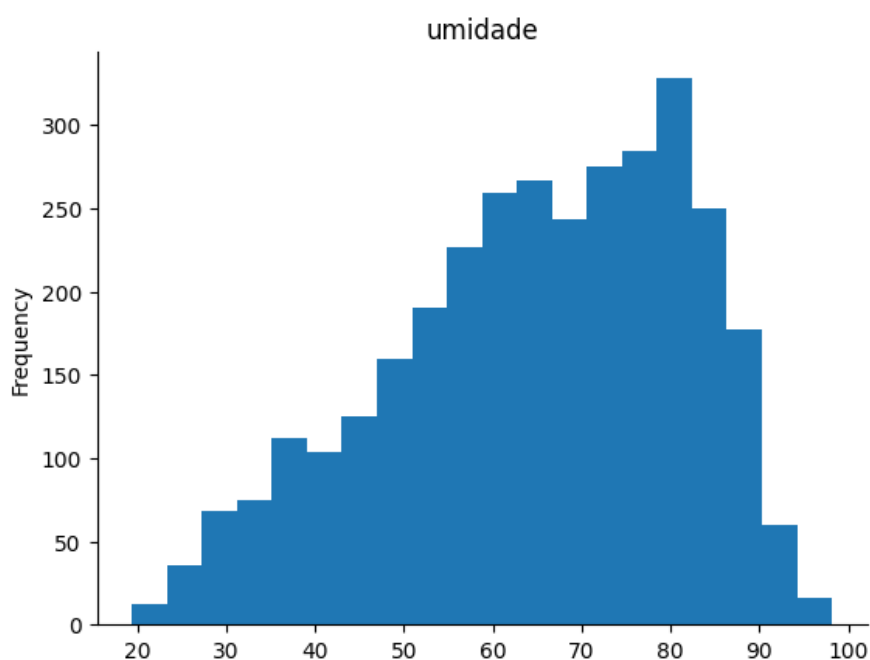
E a umidade abaixo dos 12%, para o nível laranja a temperatura tem que estar acima dos 35 °C e a umidade abaixo dos 20%, para o amarelo a temperatura tem que estar acima dos 30 °C e a umidade abaixo dos 30%.


Quando o LED vermelho é acionado, um buzzer também é ativado, simulando um alarme que notificaria as autoridades competentes e as comunidades próximas.

Dados

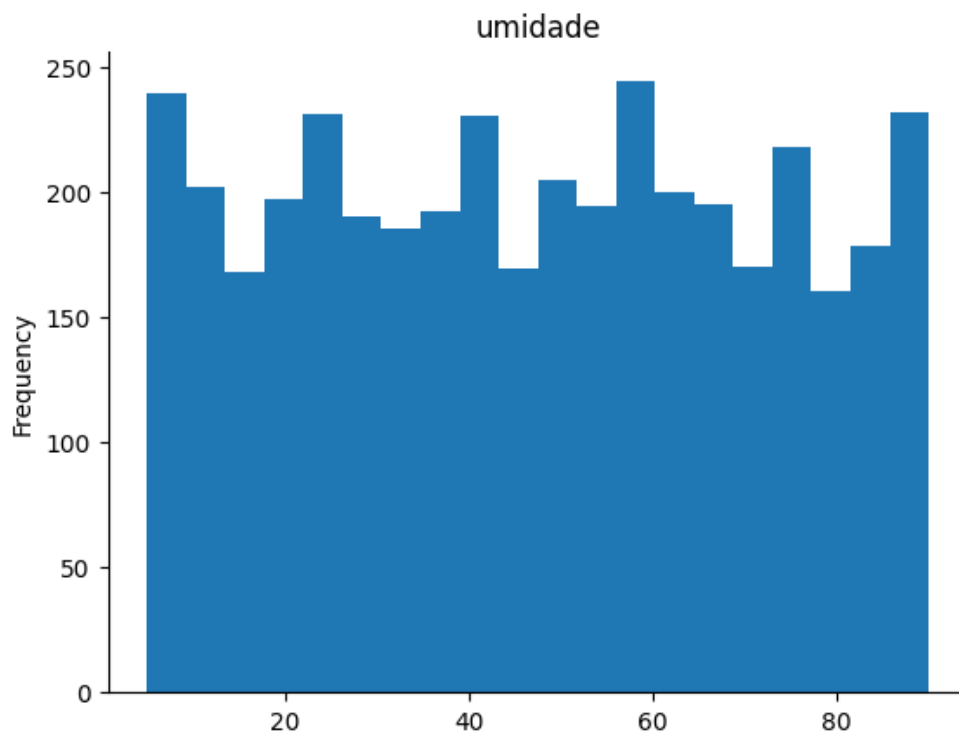
Eu coletei dados do site <https://portal.inmet.gov.br/dadoshistoricos> dos anos de 2010 até 2025 da região de Brasília para esse projeto, com isso os dados combinados foram de 3268 linhas, uma para cada dia.


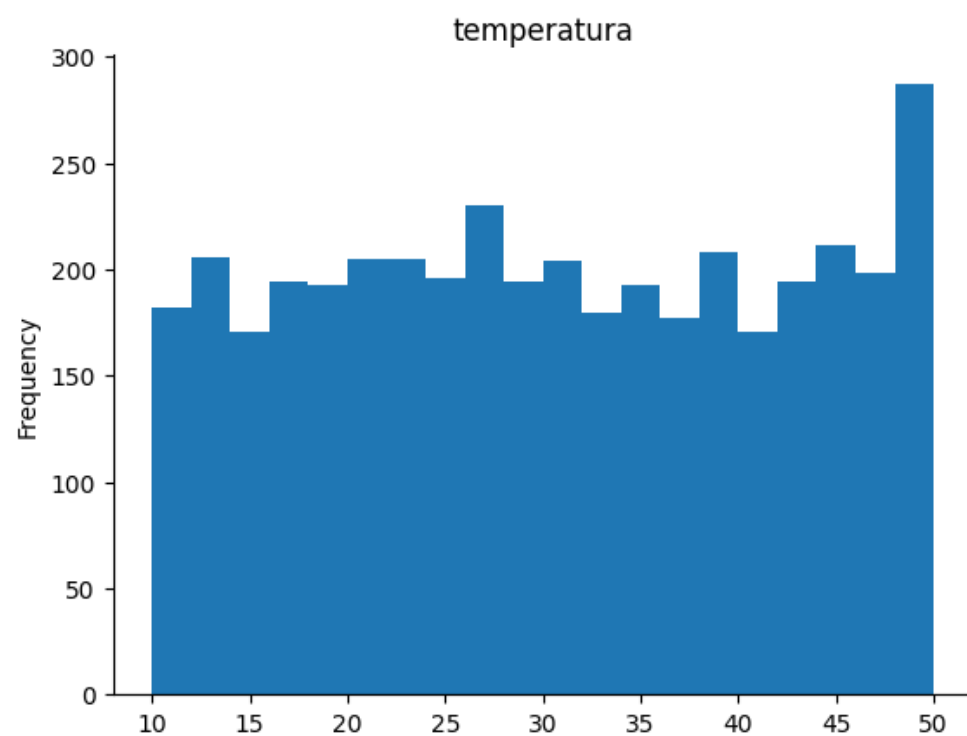
Abaixo podemos observar a tendencia dos dados





Como os valores de temperatura e umidade medidos inicialmente resultavam apenas em alerta verde, foi necessário criar uma base de dados sintética para treinar melhor o modelo de machine learning. Essa base contém 4000 registros, com valores de temperatura variando aleatoriamente entre 10 °C e 50 °C, e umidade entre 5% e 90%. Dessa forma, foi possível obter uma distribuição mais abrangente dos níveis de alerta, como pode ser observado nos gráficos a seguir.





Machine Learning e Resultados

Para este projeto foi utilizado os seguintes modelos de ML: Random Forest com acurácia de 1.00, SVM com acurácia de 0.98, KNN com acurácia de 1.00, Naive Bayes com acurácia de 0.94 e por fim Regressão logística com acurácia de 0.93.

Abaixo também pode-se observar a precisão, recall, F1-score e a matriz de confusão.

```
Acurácia: 1.00
Precisão (Weighted): 1.00
Recall (Weighted): 1.00
F1-Score (Weighted): 1.00
Matriz de Confusão:
[[1031  0  0  0]
 [  0  59  0  3]
 [  0  0  17  0]
 [  1  0  0  89]]
```

Conclusão

Como a tarefa de predição é relativamente simples, todos os modelos de machine learning testados apresentaram resultados bastante satisfatórios. Mesmo o modelo com pior desempenho, a regressão logística, alcançou uma acurácia de 93%, o que já é considerado um excelente resultado. Os demais modelos, incluindo algoritmos mais robustos, chegaram a atingir 100% de acurácia sobre os dados de teste.